

Detecting X-Outliers in Load Curve Data in Power Systems

Los datos de la curva de carga registran el consumo de energía eléctrica en intervalos de tiempo y desempeñan un papel importante en la operación y planificación de los sistemas eléctricos. Desafortunadamente, las curvas de carga suelen contener datos anómalos, ruidosos, no representativos y faltantes debido a diversos factores aleatorios.

El artículo presenta una clase diferente de valores atípicos X , los cuales tienen consumos de energía anómalos de acuerdo con una ***periodicidad*** conocida (eje X). La suposición es que el conjunto de datos sigue una periodicidad y que la duración (pero no el patrón) de dicha periodicidad es conocida.

Los datos de la curva de carga se refieren a los consumos de energía registrados por los medidores en intervalos de tiempo. Dos características clave en las redes inteligentes son la autorrecuperación ante eventos de perturbación eléctrica y la participación activa de los consumidores en la respuesta a la demanda. La recopilación de datos válidos de la curva de carga es fundamental para respaldar la toma de decisiones en los sistemas de medición inteligente y redes inteligentes.

Antes de que los datos de la curva de carga puedan utilizarse para la previsión de la demanda, el modelado y el análisis del sistema, una tarea importante es identificar y corregir los datos anómalos que no representan los patrones de consumo subyacentes, denominados “valores atípicos”

Valores atípicos en Y. Una curva de carga es una serie temporal donde el eje Y representa el consumo de energía o potencia, y el eje X representa el tiempo. La detección de valores atípicos en series temporales ha sido un tema de estudio en minería de datos (chechar referencias [1]–[3]) y estadística (chechar referencia [4]). La mayoría de los trabajos previos se han centrado en valores atípicos cuyos valores en el eje Y son inválidos en comparación con los comportamientos dentro de un entorno temporal local. A estos valores atípicos los llamamos valores atípicos en Y. Las técnicas de suavizado han sido utilizadas con éxito para detectar valores atípicos en Y [5].

Los valores atípicos en **Y** son aquellas observaciones que se desvían significativamente de la curva de suavizado.

Una **serie temporal** es un conjunto de datos ordenados en el tiempo, donde cada dato representa una observación tomada en un instante o período específico. Se utilizan para analizar la evolución de una variable a lo largo del tiempo y detectar patrones como tendencias, estacionalidad o variaciones cíclicas.

Valores atípicos en X. Los datos de la curva de carga presentan alguna forma de periodicidad *flexible* (por ejemplo, diaria, semanal, mensual, estacional, anual). El término "flexible" significa que los valores reales de los datos pueden variar, pero la tendencia de los datos se repite regularmente en ciertos intervalos. En estadística, este tipo de periodicidad se conoce como **estacionalidad**.

En muchas series temporales, los datos siguen un patrón que se repite con cierta regularidad. Por ejemplo:

- Diario:** El consumo de energía aumenta en la mañana y disminuye en la noche.

- Semanal:** El consumo de energía es diferente entre días laborables y fines de semana.

- Estacional:** En invierno, el consumo de calefacción es mayor; en verano, el de aire acondicionado.

Nótese que esta periodicidad no es exacta. El consumo de energía en un lunes puede no ser exactamente igual al del lunes anterior, pero sigue una tendencia similar. Por eso se dice que es una **periodicidad flexible**.

Diferencia clave entre Y-outlier y X-outlier	
Y-OUTLIER	X-OUTLIER
Valores inesperadamente altos o bajos en comparación con la tendencia esperada.	Ocurren cuando hay una alteración en el patrón de periodicidad (por ejemplo, si un día festivo cambia drásticamente el consumo eléctrico esperado para un lunes normal).

En la investigación del artículo indica que los datos anómalos pueden ocurrir como una desviación de tales periodicidades. Por lo que, el término **valores atípicos en X** se refiere a tales desviaciones.


Los **valores atípicos en X** son causados por eventos aleatorios como fallos en los sistemas de medición de datos o de transferencia, cortes de energía, paradas completas o parciales no programadas de líneas de producción, huelgas no programadas, cambios climáticos temporales, etc. Por lo tanto, antes de que los datos puedan ser utilizados, tales datos no representativos deben ser identificados y corregidos. El último caso es causado por eventos aleatorios como cortes de energía, cambios temporales en el clima, huelgas sindicales, mantenimiento no programado, etc. Identificar los datos afectados en este caso es precisamente la motivación de este trabajo.

Otro propósito de identificar los **valores atípicos en X** es enfocar investigaciones adicionales en las áreas potencialmente problemáticas de los datos y encontrar la causa de los datos inusuales.


Dado que los **valores atípicos en X** son desviaciones de una periodicidad, dichos valores atípicos no pueden ser detectados al examinar un vecindario local por dos razones:

- Verificar las desviaciones de una periodicidad requiere identificar el patrón periódico, lo que implica examinar los datos en todos los períodos.
- Un **valor atípico en X** podría durar un tiempo considerable y formar su propia tendencia en un vecindario de tamaño considerable, lo que podría engañar a todos los métodos basados en información local.


Por lo que todas las técnicas basadas en vecindarios, como el promedio y las técnicas de suavizado comunes, no son efectivas para detectar **valores atípicos en X**.



(a)



(b)



(c)

El problema con las técnicas tradicionales de suavizado es que ignoran la información de periodicidad. Si se utilizara el conocimiento sobre la periodicidad, los datos de la primera semana no se considerarían normales porque no se repiten en otras semanas.

OBJETIVOS DEL PAPER

- Se presenta una nueva clase de **valores atípicos en X** bajo la suposición de que los datos siguen una forma flexible de periodicidad y se conoce la longitud (pero no el patrón) de la periodicidad.
- Se propone un nuevo método para detectar y corregir **valores atípicos en X**.
- Se utilizaron datos de la curva de carga de BC Hydro para evaluar el método propuesto. La evaluación muestra que el método propuesto es capaz de detectar con éxito los **valores atípicos en X**.
- El enfoque de este artículo es identificar y limpiar un nuevo tipo de datos corruptos en los registros históricos.

SUPOSICIÓN

La única suposición realizada en este enfoque es que ***la serie temporal sigue una periodicidad y que la longitud de la periodicidad es conocida***. Los datos de la curva de carga cumplen con esta suposición porque el uso de electricidad sigue ciertas periodicidades en la vida real. El único caso que limita la aplicación de este método es cuando los datos no tienen un período o cuando la longitud de la periodicidad es desconocida para el usuario.

DEFINICIONES

Una curva de carga $T = \{(t_i, y_i)\}_{i=1}^n$ es una secuencia ordenada de observaciones con valores reales, donde y_i es el valor observado en el tiempo t_i . Una subcurva de carga $C = \{(t_i, y_i)\}_{i=j}^k$ de T es una parte continua de T donde $1 \leq j$ y $k \leq n$

Como se mencionó anteriormente, los datos de la curva de carga tienen una forma flexible de periodicidad. De manera informal, una periodicidad flexible de longitud T significa que la carga en el tiempo t es similar a la carga en los tiempos correspondientes de otros períodos, sujeta a la variabilidad en el tiempo y la carga causada por ruidos de fondo. En otras palabras, se observa una "tendencia" similar en todos los períodos, incluso si la carga real en los tiempos correspondientes puede ser diferente.

Para esto se asume que una curva de carga sigue una periodicidad flexible y que la longitud (pero no el patrón) de la periodicidad es conocida.

Definición 2: Dada una curva de carga que sigue una periodicidad flexible de una longitud conocida, un X-outlier es una subcurva máxima de carga que se desvía de la periodicidad.

La longitud de un X-outlier está determinada por la duración del evento aleatorio que causa el outlier, mientras que la longitud de la periodicidad está determinada por la regularidad de los patrones en los datos.

Por ejemplo, para un conjunto de datos con periodicidad anual, la longitud de la periodicidad es de 12 meses; si una fábrica se detiene durante 3 meses, el X-outlier tiene una longitud de 3 meses; si una huelga sindical dura 1.5 semanas, este X-outlier tiene una longitud de 1.5 semanas.

Definición 3: Dada una curva de carga que sigue una periodicidad flexible de una longitud conocida, el problema de detección de outliers es identificar todos los X-outliers.

MÉTODO PROPUESTO

Para detectar outliers, primero necesitamos modelar la tendencia general de los datos, ignorando los ruidos de fondo. Dado que los datos siguen una periodicidad, la tendencia tiende a ser periódica, es decir, se repite a intervalos iguales a la longitud conocida de la periodicidad, con posibles desviaciones. Luego, detectamos los outliers identificando todas las desviaciones de esta tendencia periódica.

ALGORITMO PROPUESTO

1. Aproximar los datos de la curva de carga utilizando una curva de suavizado, que capture la tendencia general de los datos.
2. Representar la curva de suavizado mediante una secuencia de valles y picos, llamados formas $\cup$ y formas $\cap$, que son los lugares potenciales donde podrían ocurrir los outliers.
3. Identificar los outliers como los valles y picos que no se repiten según la longitud conocida de la periodicidad.
4. Reparar los outliers.

Kernel Smoothing

1

El primer paso para detectar outliers es modelar los patrones intrínsecos de los datos de la curva de carga mediante una curva de suavizado. Dada la serie temporal de los datos de la curva de carga $T = \{(t_i, y_i)\}_{i=1}^n$ la relación de regresión de los datos puede ser modelada por una función continua

$$y_i = m(t_i) + \varepsilon_i \quad (i = 1, \dots, n).$$

Esta función está compuesta por la función de regresión y el error de observación ε_i . El valor estimado en la función de regresión en el tiempo t se modela en una forma de regresión no paramétrica por:

$$\widehat{m}(t) = \frac{1}{n} \sum_{i=1}^n w_i(t) y_i \quad (2)$$

Donde $\{w_i(t)\}_{i=1}^n$ denota una secuencia de pesos. La ecuación (2) se llama la curva de suavizado. El suavizado por núcleo, se da por:

$$w_i(t) = \frac{\text{Kern}_h(t - t_i)}{\widehat{f}_h(t)} \quad (3)$$

Donde

$$\text{Kern}_h(t) = \frac{1}{h} \text{Kern}\left(\frac{t}{h}\right) \quad (4)$$

es el núcleo con el factor de escala h . Al usar el estimador de densidad $\widehat{f}_h(t)$ de núcleo de Rosenblatt-Parzen

$$\widehat{f}_h(t) = n^{-1} \sum_{i=1}^n \text{Kern}_h(t - t_i) \quad (5)$$

Al sustituir estas expresiones en la ecuación (2) tenemos que:

$$\widehat{m}_h(t) = \frac{n^{-1} \sum_{i=1}^n \text{Kern}_h(t - t_i) y_i}{n^{-1} \sum_{i=1}^n \text{Kern}_h(t - t_i)}. \quad (6)$$

La forma de los pesos del núcleo está determinada por la función Kern, mientras que el tamaño de los pesos está parametrizado por ***h***, que se llama ancho de banda y se denomina parámetro de suavizado. Un valor grande de ***h*** corresponde a una curva más suave. En este artículo, kern se elige como la función de densidad de probabilidad normal.

$$\text{Kern}(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}t^2}. \quad (7)$$

Un outlier tiene una tendencia inusual en el eje Y según la periodicidad dada. Por lo tanto, con la tendencia de la curva de carga modelada por la curva de suavizado, un outlier tiende a ocurrir en un "valle" o un "pico" de la curva de suavizado, donde la curva de suavizado tiene valores mínimos o máximos locales

La pendiente en un tiempo t_i para una curva de suavizado $\{t_i, m_i\}_{i=1}^n$ está definido por $\frac{\Delta m_i}{\Delta t_i}$, donde $\Delta m_i = m_i - m_{i-1}$, $\Delta t_i = t_i - t_{i-1}$ para $2 \leq i \leq n$. Un tiempo en un intervalo se llama "punto de tiempo empinado" si el valor absoluto de la pendiente en el tiempo t es máximo en el intervalo (en otras palabras, en un punto de tiempo empinado, donde la curva de suavizado asciende o desciende a la tasa máxima en el intervalo considerado). Nótese que podría haber más de un punto de tiempo empinado en un intervalo.

Un intervalo $[a, b]$ es maximal-decreasing si la pendiente en cada punto de tiempo en $[a, b]$ es ≤ 0 y cualquier intervalo que contenga $[a, b]$ tiene al menos un punto con una pendiente positive.

Para dos puntos de tiempo c y c' en un intervalo maximal-decreasing, $[a, b]$ y $[c, b]$ se dice que c es convexo-decreciente si es el punto de tiempo empinado más a la derecha en el intervalo y se dice que es cóncavo-decreciente si c' es el punto de tiempo empinado más a la izquierda en el intervalo.





Fig. 2. Smoothing curve $[t_1, t_{12}]$. The horizontal axis is time. The values on the curve are the slopes at each point. $[t_1, t_5]$ is a maximal-decreasing interval; $[t_6, t_{10}]$ is a maximal-increasing interval. $[t_4, t_8]$ is a U shape.

Definición (Forma U). Para una curva suavizada, una curva de la forma U es una subcurva de $T_U = \{(t_p, m_p)\}_{p=i}^j$ tal que, para alguna k con $i \leq k \leq j$, es un intervalo decreciente-convexo y $[k + 1, j]$ es un intervalo creciente convexo.

Definición (Forma $\cap$). Para una curva suavizada, una curva de la forma $\cap$ es una subcurva de $T_U = \{(t_p, m_p)\}_{p=i}^j$ tal que, para alguna k con $i \leq k \leq j$, $[i, k]$ es un intervalo creciente cóncavo y $[k + 1, j]$ es un intervalo cóncavo decreciente.



Intervalo con forma U Intervalo con forma $\cap$

Intuitivamente, las formas capturan las regiones de la curva de suavizado donde la curva de carga sin procesar presenta grandes caídas y grandes aumentos. Estas regiones son los lugares potenciales donde pueden ocurrir outliers.

Definición 6 (Regiones Candidatas): Una región candidata a un outlier es la región correspondiente a una forma en la curva de suavizado.

Cabe recordar que la longitud de una forma, y por lo tanto la longitud de una región candidata, está determinada por la amplitud de una caída o un aumento en la curva de suavizado, lo cual es independiente de la longitud de la periodicidad. No existe correlación entre una región candidata y un período de la periodicidad.

IDENTIFICACIÓN DE OUTLIERS

Si una región candidata contiene un valor atípico real depende de si los datos en esa región se desvían de la periodicidad establecida. Una candidata **no** es un valor atípico real si datos similares de carga ocurren regularmente en otros periodos según la periodicidad. La similitud debe considerar el ruido de fondo y los desplazamientos temporales de la periodicidad.

Para identificar todos los valores atípicos, consideramos cada región candidata encontrada en el paso anterior. Sea C^* la porción de los datos crudos de la curva de carga contenida en la región candidata. Es importante notar que C^* contiene los datos originales de la curva de carga, y no los datos de la curva suavizada.

Si los datos en C^* aparecen aproximadamente en las regiones correspondientes de diferentes periodos, entonces C^* **no** es un valor atípico real, sino parte de la periodicidad. Para este propósito, extraemos todas las subcurvas de carga $C_1, C_2, \dots, C_K$, donde cada C_i es la porción de la curva de carga original en la región correspondiente a C^* en el i -ésimo periodo. Si C^* es **similar** a la mayoría de los casos normales, entonces **no** es un valor atípico real. En caso contrario, C^* se considera un valor atípico real.

¿Cómo medir la similitud entre dos subcurvas de la misma longitud?

Existen dos consideraciones al elegir una métrica de similitud:

Menor sensibilidad al ruido de fondo: La medida de similitud debe ser poco sensible al ruido de fondo. Por ejemplo, en la Figura 3, las dos curvas de carga deberían considerarse similares a pesar de la variabilidad en el primer pico debido al ruido de fondo.




Fig. 3. Two similar load curves with noises.

Menor sensibilidad a desplazamientos y estiramientos temporales: La métrica de similitud debe ser resistente a los desplazamientos y estiramientos temporales, fenómenos comunes en los datos de curvas de carga. Por ejemplo, en la Figura 4, dos curvas de carga deberían considerarse similares a pesar de un pequeño desplazamiento y estiramiento en el tiempo.




Fig. 4. Two similar load curves with time shifting and stretching.

La **distancia euclidiana**, que se usa comúnmente, **no es adecuada** para este propósito, ya que es muy sensible a los desplazamientos y estiramientos temporales. Si se utilizara la distancia euclidiana, las dos curvas en la Figura 4 serían clasificadas como distintas.

Tampoco es adecuada la **distancia de Dynamic Time Warping (DTW)**, que compara dos secuencias emparejando todos sus puntos (como se muestra en la Figura 5). Esto impide ignorar puntos ruidosos, lo que no es deseable para nuestro análisis.




Fig. 5. Pairing strategy of DTW.

Lo que se necesita es una métrica de similitud que examine un pequeño vecindario en busca de puntos coincidentes y pueda omitir puntos ruidosos. Para este propósito, se puede adoptar el concepto de Longest Common Sub-Sequence (LCSS).

En lugar de comparar puntos exactos, LCSS mide la similitud en términos de “tendencias”. Dadas dos subcurvas de carga A y B, correspondientes a dos períodos distintos, queremos encontrar la **subsecuencia común más larga (LCSS)** entre ambas. La idea es la siguiente:

Para permitir desplazamientos y estiramientos temporales, se examinan los puntos de carga dentro de una cierta proximidad temporal en busca de coincidencias. Si estos puntos de carga son similares, se consideran una coincidencia y se conservan. Los valores disímiles en una o ambas curvas de carga se descartan.

Matemáticamente, dado un entero δ y un valor real ϵ , la **similitud acumulativa** se define como:

$$S_{i,j} = \begin{cases} 0, & \text{if } i = 0 \vee j = 0 \\ 1 + S_{i-1,j-1}, & \text{if } |a_i - b_j| \leq \epsilon \\ & \wedge |i - j| \leq \delta \\ \max(S_{i,j-1}, S_{i-1,j}) & \text{otherwise.} \end{cases}$$